

Estimativa da Recorrência de Violência contra a Pessoa Idosa a partir de Dados do SINAN Utilizando Aprendizado de Máquina

Nicole Moritz e Morgane De Avila

Universidade Federal da Fronteira Sul

Chapecó – SC – Brasil

Resumo. A violência contra a pessoa idosa é um problema de saúde pública cuja recorrência pode ampliar situações de vulnerabilidade. Este trabalho desenvolve e avalia modelos de aprendizado de máquina supervisionado a partir de registros do Sistema de Informação de Agravos de Notificação (SINAN), com o objetivo de estimar a recorrência registrada de violência envolvendo pessoas com 60 anos ou mais. Foram utilizados os microdados de 2024, submetidos a critérios de seleção, análise de qualidade, pré-processamento e engenharia de atributos. A amostra final de modelagem foi composta por 25.052 notificações de violência interpessoal. Foram comparados regressão logística, Random Forest e HistGradientBoosting, além de um classificador de referência. O HistGradientBoosting apresentou o melhor desempenho discriminativo, com AUC-ROC de 0,845 no conjunto de teste. O modelo é investigado como componente de um artefato de apoio à priorização de casos para revisão humana, sem substituir a avaliação profissional ou os protocolos de proteção existentes.

1. Introdução

O envelhecimento populacional brasileiro vem ocorrendo de forma acelerada e produz novas demandas para as políticas públicas de saúde, assistência social e proteção de direitos. Dados do Censo Demográfico 2022 indicam que o Brasil possuía aproximadamente 32,1 milhões de pessoas com 60 anos ou mais, contingente substancialmente superior ao registrado no Censo de 2010 [Instituto Brasileiro de Geografia e Estatística, 2023]. À medida que aumenta a participação das pessoas idosas na população, torna-se também mais relevante desenvolver mecanismos de prevenção, identificação precoce e resposta a situações que comprometem sua integridade, autonomia e qualidade de vida.

Entre essas situações, destaca-se a violência contra a pessoa idosa, reconhecida como problema de saúde pública e de garantia de direitos. Ela pode assumir diferentes formas, como violência física, psicológica ou moral, sexual, financeira ou econômica, negligência e abandono, frequentemente ocorrendo em relações nas quais existe proximidade ou dependência entre vítima e agressor. Estudos baseados em notificações do setor

saúde evidenciam a complexidade desse fenômeno e sua presença em diferentes regiões do país [Mascarenhas et al., 2012].

Em análise nacional das notificações do SINAN referentes a 2017, Andrade et al. [Andrade et al., 2023] observaram que 76,9% dos casos ocorreram no domicílio e que 49,5% foram registrados como violência recorrente. Na amostra de 2024 analisada neste trabalho, 53,3% dos registros com resposta válida para recorrência foram classificados como recorrentes. Os valores são próximos e reforçam a importância de investigar fatores associados à repetição das agressões.

No Brasil, a vigilância de violências é realizada, entre outros instrumentos, por meio do VIVA/SINAN. A notificação de violência doméstica, sexual e de outras violências é compulsória nos serviços de saúde, e a ficha reúne informações sociodemográficas da vítima, características da ocorrência e dados sobre o provável autor. Entre seus campos está a variável “Ocorreu outras vezes?”, destinada a indicar se o evento já havia acontecido anteriormente, com respostas “sim”, “não” ou “ignorado” [Brasil. Ministério da Saúde, 2016]. Embora esse campo permita estudar recorrência, sua utilização exige cautela: o próprio Ministério da Saúde recomenda a análise da completude e da consistência das bases do SINAN [Brasil. Ministério da Saúde, 2019], e pesquisas com notificações de violência contra pessoas idosas apontam problemas de preenchimento em variáveis relevantes [Lima et al., 2023].

Esse cenário conduz ao problema investigado neste trabalho: é possível estimar, a partir dos campos da ficha de notificação do SINAN, a probabilidade de recorrência da violência contra a pessoa idosa de modo a apoiar a priorização de casos para revisão nos serviços de proteção? A questão é especialmente relevante porque, em pessoas idosas, limitações de comunicação, dependência de terceiros e vínculos próximos com o agressor podem dificultar a obtenção de informações completas. Assim, o campo de recorrência deve ser entendido como um rótulo de notificação sujeito a incertezas, e não como uma representação perfeita da realidade.

Técnicas de aprendizado de máquina podem contribuir nesse contexto por identificar padrões em grandes bases de dados e combinar simultaneamente características como tipo de violência, local da ocorrência, relação com o provável agressor, faixa etária, sexo, escolaridade e suspeita de uso de álcool. Há precedente recente para o emprego de inteligência artificial em dados de violência do SINAN: Bandiera-Paiva et al. [Bandiera-Paiva et al., 2026] aplicaram técnicas de ciência de dados e modelagem preditiva a notificações de violência contra mulheres no município de São Paulo. Contudo, permanece uma lacuna quanto ao uso desses métodos para estudar especificamente pessoas idosas e a recorrência da violência em notificações brasileiras.

Diante disso, o objetivo geral deste estudo é desenvolver e avaliar modelos de aprendizado de máquina capazes de estimar, a partir dos dados registrados nas fichas de notificação do SINAN, a probabilidade de uma ocorrência de violência contra pessoa com 60 anos ou mais ser classificada como violência de repetição. Em vez de fornecer apenas uma classificação binária, pretende-se produzir uma estimativa entre 0 e 1 que possa ser analisada como um escore complementar de apoio à organização da revisão dos casos. Essa saída não deverá ser interpretada como decisão automática sobre atendimento, proteção ou responsabilização, mas como informação adicional para análise profissional.

A relevância da proposta é simultaneamente social, científica e metodológica. Socialmente, a recorrência indica que parte importante das notificações não corresponde a episódios isolados. Cientificamente, o estudo aproxima técnicas de ciência de dados de um problema de saúde pública utilizando dados brasileiros. Metodologicamente, permite investigar até que ponto informações já disponíveis no SINAN apresentam capacidade discriminativa para ordenar casos segundo a recorrência registrada. Como sistemas algorítmicos aplicados à saúde podem reproduzir desigualdades e vieses existentes nos registros, são consideradas salvaguardas como documentação das limitações da base, supervisão humana e futura avaliação por subgrupos, em consonância com orientações internacionais para inteligência artificial em saúde [World Health Organization, 2021].

2. Trabalhos Relacionados

Bandiera-Paiva et al. [Bandiera-Paiva et al., 2026] propuseram o framework *Health Research Standard Process for Artificial Intelligence* (HRSP-AI) e o aplicaram à análise de violência contra mulheres no município de São Paulo. O trabalho utilizou dados do SINAN entre 2013 e 2023 e combinou preparação de dados, análises sociodemográficas e espaciais, séries temporais e técnicas de inteligência artificial. Como resultado, os autores demonstraram a viabilidade do framework para organizar análises de dados de saúde e desenvolver componentes preditivos, além de apresentar uma matriz metodológica replicável. Esse estudo é especialmente próximo ao presente trabalho por empregar a mesma fonte nacional de notificações, embora trate de outra população e não tenha como variável-alvo a recorrência da violência contra pessoas idosas.

Zeng et al. [Zeng et al., 2025] investigaram fatores associados ao abuso de pessoas idosas no ambiente familiar e buscaram identificar diferenças entre tipos de violência. A pesquisa utilizou 10.703 registros da *China Longitudinal Aging Social Survey* e aplicou um classificador *Random Forest* para estimar a importância das variáveis. Os resultados apontaram como fatores de maior importância a condição econômica dos filhos, o número de filhos, o estado de saúde da pessoa idosa, as relações intergeracionais, a pressão de tempo sobre os filhos e a oferta de serviços domiciliares de cuidado. O estudo evidencia a utilidade de modelos supervisionados para identificar padrões relacionados à violência contra idosos, mas utiliza dados de pesquisa amostral e tem como foco a ocorrência de abuso, e não sua recorrência em registros de vigilância.

Pappadis et al. [Pappadis et al., 2025] desenvolveram e validaram internamente um modelo preliminar para prever diagnóstico de maus-tratos contra pessoas idosas em um horizonte de dois anos. Foram analisados 2.261.166 beneficiários do Medicare com 66 anos ou mais, utilizando regressão logística, *Random Forest*, árvores com *gradient boosting* e perceptron multicamadas. Os preditores incluíram características demográficas, comorbidades, sinais clínicos e determinantes sociais. A regressão logística completa obteve AUC de 0,7253 e sensibilidade de 0,8007, enquanto o *Random Forest* apresentou a maior sensibilidade, de 0,8119. Os autores também observaram diferenças de desempenho entre grupos demográficos, reforçando a necessidade de avaliar possíveis vieses dos modelos. Embora o desfecho seja a identificação futura de maus-tratos e não a recorrência de uma notificação, o trabalho oferece referência importante para comparação de algoritmos, calibração e análise por subgrupos.

Oguztuzun et al. [Oguztuzun et al., 2025] utilizaram aprendizado de máquina in-

interpretável para estudar reincidência de agressão física em casos de violência por parceiro íntimo. A pesquisa empregou dados de um estudo clínico longitudinal de quatro anos e comparou algoritmos como SVM, regressão logística, Naive Bayes, k-vizinhos mais próximos, *Random Forest*, XGBoost, AdaBoost e CatBoost, com validação cruzada em cinco partes. A acurácia dos modelos permaneceu próxima de 60% para a maior parte dos algoritmos, e análises de importância de atributos indicaram que combinar informações relatadas pelo agressor e pela parceira melhorou o poder preditivo. O estudo é relevante por tratar diretamente de reincidência e por enfatizar interpretabilidade, apesar de envolver outro tipo de violência, outra população e uma base clínica de menor escala.

A Tabela 1 sintetiza as aproximações e diferenças entre os estudos. Observa-se que os trabalhos existentes cobrem separadamente elementos centrais desta pesquisa: uso do SINAN e inteligência artificial, predição de violência contra pessoas idosas e modelagem de reincidência. Entretanto, entre os estudos analisados, não foi identificado um trabalho que reúna simultaneamente o recorte de pessoas com 60 anos ou mais, os registros brasileiros do SINAN e a estimativa probabilística da recorrência como desfecho principal. Essa combinação constitui a principal distinção da proposta.

Tabela 1: Comparação entre os trabalhos relacionados e a pesquisa proposta.

Trabalho	Dados/população	Abordagem	Principal diferença
Bandiera-Paiva et al. (2026)	SINAN; violência contra mulheres em São Paulo	Ciência de dados, séries temporais e IA	Usa SINAN e IA, mas não focaliza pessoas idosas nem recorrência como alvo.
Zeng et al. (2025)	Survey longitudinal; 10.703 pessoas idosas na China	Random Forest	Focaliza abuso de idosos, porém não usa SINAN e não estima recorrência de notificações.
Pappadis et al. (2025)	Medicare; 2.261.166 pessoas com 66 anos ou mais	Regressão logística, RF, GBDT e MLP	Prediz diagnóstico futuro de maus-tratos, não recorrência registrada em notificações.
Oguztuzun et al. (2025)	Estudo clínico longitudinal sobre violência por parceiro íntimo	Diversos classificadores	Prediz reincidência, mas em outra população e com dados clínicos.
Pesquisa proposta	SINAN; pessoas com 60 anos ou mais	Classificação supervisionada	Estima especificamente recorrência de violência contra idosos em notificações brasileiras.

3. Metodologia

A pesquisa possui caráter quantitativo, observacional e retrospectivo e utiliza dados secundários provenientes das notificações de violência do Sistema de Informação de Agravos de Notificação (SINAN). O desenvolvimento metodológico é conduzido com base na *Design Science Research Methodology* (DSRM), proposta por Peffers et al. [Peffers et al., 2007]. A DSRM organiza a construção e a avaliação de artefatos orientados à solução de problemas, sendo utilizada neste estudo para estruturar o desenvolvimento do classificador e sua relação com o problema de priorização das notificações.

3.1. DSRM e ciclo de vida do aprendizado de máquina

A primeira etapa da DSRM corresponde à identificação do problema e à motivação. No contexto deste projeto, o problema identificado consiste na organização das notificações sem um mecanismo automatizado de priorização segundo a recorrência estimada. A segunda etapa corresponde à definição dos objetivos da solução: desenvolver um escore

capaz de auxiliar a ordenação da fila conforme a recorrência estimada, sem excluir casos do atendimento e sem substituir a análise realizada pelos profissionais responsáveis.

A fase de *Design e Desenvolvimento* engloba o ciclo de vida do aprendizado de máquina executado nesta etapa do projeto. Ela compreende obtenção e compreensão dos dados, definição da variável-alvo, pré-processamento, engenharia e seleção de atributos, divisão da amostra, treinamento dos modelos, validação cruzada e seleção do algoritmo. Dessa forma, decisões sobre tratamento dos dados, codificação das variáveis categóricas, criação de atributos e prevenção de vazamento de informação são consideradas decisões de projeto do artefato.

A fase de *Demonstração* corresponde à aplicação dos modelos em dados não utilizados no ajuste, por meio da comparação com um classificador de referência e da análise das métricas no conjunto de teste retido. Já a fase de *Avaliação* será aprofundada posteriormente por meio da análise de calibração, auditoria de possíveis vieses, avaliação entre subgrupos e validação do artefato em relação ao contexto real de utilização. Assim, nesta etapa demonstra-se a capacidade preditiva do artefato em ambiente controlado, enquanto sua utilidade prática permanece como etapa subsequente. A comunicação dos resultados ocorre por meio deste artigo e das etapas posteriores do projeto.

3.2. Fonte dos dados e seleção da amostra

Foram utilizados os microdados de 2024 do VIVA/SINAN, disponibilizados pelo Ministério da Saúde por meio do DATASUS. Os arquivos correspondem às notificações de violência interpessoal e autoprovocada registradas durante o ano de referência. Os dados foram obtidos a partir dos arquivos públicos do SINAN e processados com auxílio da biblioteca *PySUS*. A interpretação dos campos foi baseada no dicionário do SINAN NET e nas orientações oficiais do Ministério da Saúde para análise da qualidade das bases de dados [Brasil. Ministério da Saúde, 2016, Brasil. Ministério da Saúde, 2019].

A base inicialmente utilizada continha 616.548 notificações de violência registradas em 2024. Destas, 42.176 correspondiam a vítimas com 60 anos ou mais, representando aproximadamente 6,8% do total. Foram excluídas 7.033 notificações classificadas como violência autoprovocada, pois o modelo desenvolvido neste estudo se concentra em violência interpessoal e utiliza características relacionadas ao provável autor da agressão.

Após esse recorte, permaneceram 35.143 notificações de violência interpessoal contra pessoas idosas. Em seguida, foram excluídos cinco registros cuja idade foi considerada implausível, adotando-se como intervalo válido idades entre 60 e 119 anos. Também foram retirados 10.086 registros nos quais o campo utilizado como variável-alvo estava preenchido como ignorado ou não possuía valor válido. Esses registros correspondiam a aproximadamente 28,7% dos casos de violência interpessoal contra pessoas idosas. A amostra final utilizada para modelagem foi composta por 25.052 registros.

A variável-alvo foi construída a partir do campo `OUT_VEZES`, correspondente à pergunta “Ocorreu outras vezes?”. As respostas válidas foram binarizadas em 1 para recorrência e 0 para ausência de recorrência. Na amostra final, 53,3% dos registros pertenciam à classe recorrente e 46,7% à classe não recorrente. A proporção observada é próxima dos 49,5% descritos por Andrade et al. [Andrade et al., 2023] para notificações de 2017.

Tabela 2: Etapas de seleção da amostra utilizada na modelagem.

Etapas	Registros
Notificações de violência em 2024	616.548
Vítimas com 60 anos ou mais	42.176
Exclusão de violência autoprovocada	-7.033
Violência interpessoal contra pessoa idosa	35.143
Exclusão por idade implausível	-5
Exclusão por alvo ignorado ou ausente	-10.086
Amostra final de modelagem	25.052

A recorrência deve ser entendida como uma *proxy* e não como medida direta da gravidade da ocorrência. Um primeiro episódio pode apresentar consequências mais graves do que um episódio recorrente. Dessa maneira, o modelo procura estimar especificamente a recorrência registrada na ficha do SINAN.

3.3. Pré-processamento dos dados

O pré-processamento considerou particularidades da codificação dos campos do SINAN e as recomendações de análise de consistência da base apresentadas pelo Ministério da Saúde [Brasil. Ministério da Saúde, 2019]. A idade não é armazenada diretamente em anos no campo NU_IDADE_N. O primeiro dígito representa a unidade da idade registrada: 1 para horas, 2 para dias, 3 para meses e 4 para anos. Os dígitos seguintes representam o valor correspondente. Assim, o valor 4065, por exemplo, corresponde a uma idade de 65 anos. Essa codificação foi considerada antes da seleção dos registros, evitando a inclusão indevida de indivíduos cuja idade estivesse registrada em horas, dias ou meses.

Também foram observadas diferenças de largura entre códigos existentes nos arquivos e os valores descritos no dicionário. Em determinados campos, o dado poderia aparecer como “1”, enquanto o dicionário utilizava “01”. O processo de tratamento foi desenvolvido para reconhecer ambas as representações.

Nas variáveis preditoras, os valores classificados como “Ignorado” foram preservados como categoria própria em vez de serem automaticamente convertidos em valores ausentes. Essa decisão considera que a ausência de informação pode refletir características do próprio processo de preenchimento das notificações, aspecto relevante diante dos problemas de completitude já descritos para dados de violência do SINAN [Lima et al., 2023].

3.4. Engenharia de atributos

Além das variáveis originalmente disponíveis na ficha, foram construídos sete atributos derivados com o objetivo de representar características potencialmente associadas à recorrência da violência.

A utilização desses atributos permite representar informações relacionadas à multiplicidade das agressões, ao vínculo com o provável agressor e às características individuais sem depender exclusivamente das categorias originais da ficha.

Tabela 3: Variáveis derivadas utilizadas na modelagem.

Variável	Construção	Justificativa
n_violence_types	Contagem dos campos de tipos de violência marcados	Representa a ocorrência simultânea de diferentes formas de violência.
n_aggression_means	Contagem dos campos relacionados aos meios de agressão	Representa a multiplicidade dos meios utilizados na agressão.
family_aggressor	Existência de algum vínculo familiar com o provável agressor	Agrupar diferentes categorias de parentesco.
household_aggressor	Cônjuge, filho, filha ou cuidador identificado como provável agressor	Representa vínculos associados à possibilidade de exposição continuada.
aggressor_identified	Existência de algum campo de relação com o provável agressor preenchido	Permite distinguir registros nos quais o autor foi identificado.
has_disability	Presença de algum dos campos relacionados a deficiência ou transtorno	Agrupar categorias individuais de baixa frequência.
age_band	Faixas 60–69, 70–79, 80–89 e 90 anos ou mais	Representa possíveis diferenças entre grupos etários.

3.5. Codificação e prevenção de vazamento de dados

As variáveis categóricas foram transformadas por meio de *one-hot encoding*, utilizando a primeira categoria como referência. O *label encoding* não foi adotado para as variáveis nominais porque a atribuição de valores numéricos poderia introduzir uma relação ordinal inexistente entre categorias. A escolaridade constitui exceção por possuir ordenação natural entre suas categorias.

A divisão dos dados em treinamento e teste ocorreu antes do ajuste das transformações. O pré-processamento foi encapsulado em um *Pipeline* utilizando *ColumnTransformer*, de forma que os transformadores fossem ajustados exclusivamente sobre o conjunto de treinamento. Essa separação é importante para evitar vazamento de informação, problema que pode produzir estimativas excessivamente otimistas de desempenho em tarefas preditivas [Kaufman et al., 2012].

Também foram excluídos 25 campos relacionados a encaminhamentos e procedimentos realizados após a conduta sobre o caso, incluindo campos dos grupos ENC_*, DELEG_*, CONS_* e PROC_*. Essas informações foram removidas porque não representam necessariamente dados disponíveis no momento de entrada de uma nova notificação. Sua utilização durante o treinamento configuraria vazamento temporal e poderia elevar artificialmente o desempenho.

Variáveis geográficas também foram excluídas do conjunto de preditores. A análise exploratória indicou diferenças relevantes na distribuição das notificações entre unidades federativas, potencialmente relacionadas à capacidade e às práticas de notificação de cada estado, e não exclusivamente ao risco individual da vítima. A variável raça/cor não foi utilizada como preditora e foi reservada para a etapa posterior de auditoria de equidade. Campos utilizados diretamente nos critérios de seleção da amostra também foram retirados quando se tornaram constantes depois do recorte.

3.6. Divisão dos dados e modelos avaliados

A amostra final foi dividida de forma estratificada em 80% para treinamento e 20% para teste. Foi utilizada uma semente fixa, com `random_state=42`, permitindo a reprodu-

ção da divisão realizada. O conjunto de teste resultante foi composto por 5.011 registros.

Foram comparados três algoritmos supervisionados: regressão logística, *Random Forest* e *HistGradientBoosting*. A regressão logística foi utilizada como modelo linear de referência, enquanto os métodos baseados em árvores foram incluídos pela capacidade de representar relações não lineares e interações entre atributos. Estudos recentes sobre predição de maus-tratos e reincidência de violência também empregaram regressão logística e métodos baseados em árvores na comparação de modelos [Pappadis et al., 2025, Oguztuzun et al., 2025].

Além dos três modelos treinados, foi utilizado um *DummyClassifier* como *baseline*. Esse classificador representa uma estratégia trivial baseada na classe majoritária e permite verificar se os modelos treinados apresentam capacidade discriminativa superior à simples reprodução da distribuição do desfecho.

No conjunto de treinamento foi realizada validação cruzada estratificada com cinco partições. As classes encontravam-se próximas do equilíbrio, com 53,3% dos registros pertencentes à classe recorrente e 46,7% à classe não recorrente. Por esse motivo, não foram aplicadas estratégias de ponderação de classes ou reamostragem nesta etapa.

3.7. Métricas de avaliação

A principal métrica adotada foi a área sob a curva ROC, denominada AUC-ROC. A curva ROC descreve a relação entre sensibilidade e taxa de falsos positivos para diferentes limiares de decisão, enquanto a AUC resume a capacidade discriminativa do modelo [Fawcett, 2006].

A escolha da AUC está diretamente relacionada ao objetivo do artefato. O sistema não pretende simplesmente produzir uma decisão binária entre recorrente e não recorrente, mas ordenar as notificações de acordo com um escore estimado. Nesse contexto, a AUC representa a capacidade do modelo de atribuir pontuações maiores a registros recorrentes do que a registros não recorrentes.

Também foram avaliadas acurácia, *recall* e precisão. O *recall* possui importância particular no contexto proposto porque um falso negativo representa um caso recorrente que recebeu uma classificação negativa e que poderia, consequentemente, receber prioridade inferior. Um falso positivo, por sua vez, representa um caso não recorrente que poderia receber atendimento antecipado. Essa diferença entre as consequências dos erros justifica a análise conjunta das métricas em vez da utilização exclusiva da acurácia.

A calibração das probabilidades constitui uma etapa complementar ainda não concluída nesta fase do projeto. Enquanto a AUC avalia a capacidade de discriminação e ordenação do modelo, a calibração deverá avaliar se os valores probabilísticos produzidos correspondem às frequências observadas. Portanto, os resultados desta etapa demonstram capacidade discriminativa, mas ainda não devem ser interpretados como evidência de que as probabilidades estejam calibradas.

3.8. Demonstração e resultados dos modelos

Os resultados obtidos pelos modelos são apresentados na Tabela 4.

O *HistGradientBoosting* apresentou a maior AUC no conjunto de teste, com valor

Tabela 4: Desempenho dos modelos avaliados.

Modelo	AUC teste	AUC CV	DP CV	Acurácia	Recall	Precisão
HistGradientBoosting	0,845	0,843	0,004	0,765	0,802	0,767
Random Forest	0,840	0,837	0,005	0,765	0,816	0,760
Regressão logística	0,826	0,829	0,004	0,753	0,792	0,756
DummyClassifier	0,500	0,500	0,000	0,533	1,000	0,533

de 0,845. O *Random Forest* apresentou AUC de 0,840, enquanto a regressão logística alcançou 0,826. O *DummyClassifier* apresentou AUC de 0,500 e acurácia de 0,533. Apesar de atingir *recall* de 1,000 por classificar todos os registros como pertencentes à classe majoritária, o modelo não possui capacidade de distinguir ou ordenar os casos. Esse resultado demonstra que o *recall* não deve ser utilizado isoladamente para selecionar o modelo.

O *HistGradientBoosting* foi selecionado como modelo de melhor desempenho devido à AUC de 0,845 no conjunto de teste, representando ganho absoluto de 0,345 em relação ao *baseline*. Na validação cruzada, o modelo apresentou AUC média de 0,843 e desvio padrão de 0,004, indicando pequena variação entre as diferentes partições do conjunto de treinamento.

No conjunto de teste, a matriz de confusão do modelo selecionado apresentou 1.691 verdadeiros negativos, 2.141 verdadeiros positivos, 651 falsos positivos e 528 falsos negativos. Esses resultados correspondem a acurácia de 0,765, *recall* de 0,802 e precisão de 0,767.

Devido ao desempenho obtido, também foi realizada uma verificação explícita das possíveis fontes de vazamento. Confirmou-se a ausência dos campos de encaminhamento e procedimento no conjunto de preditores. A análise de importância por permutação apresentou contribuição distribuída entre as variáveis, sem indicar que o desempenho estivesse concentrado exclusivamente em um único atributo.

Entretanto, o atributo relacionado à ausência de identificação do provável autor apresentou a maior importância individual. Sua permutação provocou redução de 0,0216 na AUC. Aproximadamente 13,9% dos registros não apresentavam identificação do autor mesmo em um campo previsto na ficha de notificação. Esse resultado deve ser interpretado com cautela, pois o padrão aprendido pode estar relacionado não apenas à recorrência, mas também à qualidade ou às características do preenchimento realizado pelas unidades notificadoras. Essa questão será aprofundada posteriormente durante a auditoria de possíveis vieses.

4. Considerações Finais

Os resultados desta etapa demonstram que os campos disponíveis nas notificações do SINAN possuem capacidade discriminativa para estimar a recorrência registrada de violência contra pessoas idosas. A partir das 616.548 notificações de violência registradas em 2024, os critérios de seleção produziram uma amostra final de 25.052 casos de violência interpessoal contra pessoas idosas com variável-alvo válida.

Entre os algoritmos comparados, o *HistGradientBoosting* apresentou o melhor desempenho discriminativo, alcançando AUC-ROC de 0,845 no conjunto de teste e AUC

média de 0,843 durante a validação cruzada. O resultado foi superior ao *baseline* e aos demais algoritmos avaliados, indicando que as características disponíveis nas notificações apresentam informação capaz de contribuir para a ordenação dos casos segundo a recorrência registrada.

Os resultados, entretanto, não devem ser interpretados como estimativa direta da gravidade da violência. O campo “Ocorreu outras vezes?” representa a recorrência registrada na notificação e funciona como uma *proxy*, estando sujeito à qualidade, completitude e consistência dos dados. A importância observada para atributos relacionados à ausência de informação reforça a necessidade de investigar se parte do desempenho está associada a padrões de preenchimento das unidades notificadoras.

No contexto da DSRM, esta etapa corresponde principalmente às fases de *Design e Desenvolvimento* do artefato e à sua *Demonstração* em ambiente controlado. As próximas etapas deverão incluir a análise da calibração das probabilidades, a avaliação do desempenho entre subgrupos, a auditoria de possíveis vieses e a validação do artefato no contexto real de utilização.

O artefato permanece concebido como mecanismo complementar de apoio à priorização para revisão humana. O modelo não elimina notificações da fila e não substitui decisões profissionais, protocolos de atendimento ou medidas de proteção. A decisão final permanece sob responsabilidade humana, de modo que o escore produzido funcione apenas como uma informação adicional para auxiliar a organização da análise dos casos.

Referências

- [Andrade et al., 2023] Andrade, F. M. D., Machado, E., Freitas, M. I. F., Souza, M. F. M., and Malta, D. C. (2023). Patterns of abuse of elderly people in brazil: analysis of notifications. *Cadernos de Saúde Pública*, 39(1):e00075722.
- [Bandiera-Paiva et al., 2026] Bandiera-Paiva, P., Shimaoka, A. M., Silva Junior, A. C., Araujo, L. M., Nascimento, D. D. G., Salvador, M. E., Ribeiro, M. B., Areco, K. C. N., Duarte, J. M., Mansur, N. S., and Barbosa, D. A. (2026). Uso de inteligência artificial para análise da violência contra mulheres em são paulo. *Revista de Saúde Pública*, 60:e28.
- [Brasil. Ministério da Saúde, 2016] Brasil. Ministério da Saúde (2016). *Viva: instrutivo sobre a notificação de violência interpessoal e autoprovocada*. Ministério da Saúde, Brasília, DF, 2 edition.
- [Brasil. Ministério da Saúde, 2019] Brasil. Ministério da Saúde (2019). Caderno de análise: roteiro para uso do sinan net, análise da qualidade da base de dados e cálculo de indicadores epidemiológicos e operacionais: violência interpessoal/autoprovocada. Technical report, Ministério da Saúde, Brasília, DF.
- [Fawcett, 2006] Fawcett, T. (2006). An introduction to roc analysis. *Pattern Recognition Letters*, 27(8):861–874.
- [Instituto Brasileiro de Geografia e Estatística, 2023] Instituto Brasileiro de Geografia e Estatística (2023). Censo demográfico 2022: população por idade e sexo – pessoas de 60 anos ou mais de idade. Technical report, IBGE.

- [Kaufman et al., 2012] Kaufman, S., Rosset, S., Perlich, C., and Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, 6(4):15:1–15:21.
- [Lima et al., 2023] Lima, V. M. F. et al. (2023). Caracterização e completitude das fichas de notificação de violência contra a pessoa idosa em niterói-rj, 2011–2020. *Epidemiologia e Serviços de Saúde*, 32(1):e2022451.
- [Mascarenhas et al., 2012] Mascarenhas, M. D. M. et al. (2012). Violência contra a pessoa idosa: análise das notificações realizadas no setor saúde – brasil, 2010. *Ciência & Saúde Coletiva*, 17(9):2331–2341.
- [Oguztuzun et al., 2025] Oguztuzun, C., Koyutürk, M., and Karakurt, G. (2025). Interpretable machine learning to identify risk factors for recidivism in intimate partner violence. In *AMIA Annual Symposium Proceedings*, pages 1285–1294.
- [Pappadis et al., 2025] Pappadis, M. R., Schlag, K. E., Westra, J., Wood, L., Czyz, R., Kuo, Y.-F., Raji, M. A., Temple, J. R., and Mouton, C. P. (2025). Clinical factors and social determinants of health predict elder mistreatment at two years among older adults: A preliminary prediction model. *INQUIRY: The Journal of Health Care Organization, Provision, and Financing*.
- [Peppers et al., 2007] Peppers, K., Tuunanen, T., Rothenberger, M. A., and Chatterjee, S. (2007). A design science research methodology for information systems research. *Journal of Management Information Systems*, 24(3):45–77.
- [World Health Organization, 2021] World Health Organization (2021). *Ethics and Governance of Artificial Intelligence for Health: WHO Guidance*. World Health Organization, Geneva.
- [Zeng et al., 2025] Zeng, Q., Wang, Y., Zhao, F., and He, Z. (2025). Predicting elder abuse using a random forest classifier. *Journal of Interpersonal Violence*.